

Физико-информированное предсказание растворимости: условие оптимальности физики и архитектура двойного заземления

Предварительный отчёт

Проект TGNN-Solv

18 июня 2026 г.

Аннотация

Мы исследуем, *когда* явная термодинамическая декомпозиция помогает предсказывать равновесную растворимость твёрдое–жидкость $\ln x_2 = -\Phi(T) - \ln \gamma_2$, а не просто *помогает ли* она. Отчёт фиксирует предварительные результаты по четырём направлениям: (A) оценка неустранимого шумового потолка меток; (B) теория идентифицируемости и условие оптимальности физической факторизации; (C) архитектура *двойного заземления*, где оба фактора разложения (кристаллический член и активность через σ -профиль и дифференцируемый COSMO-SAC) становятся одно-компонентными, внешне-супервизируемыми объектами; (D) оценка модели по утилите (ранжирование растворителей и калибровка неопределённости), а не только по MAE. Ключевые количественные выводы: неустранимый шумовой пол при честной межлабораторной оценке составляет $\approx 0,3\text{--}0,7 \log_{10}$, поэтому запас по абсолютной точности на новых каркасах скромный (фактор ~ 2 , не порядок); на сопоставимом режиме экстраполяции наша модель ($\approx 1,0 \log_{10}$ RMSE) немного уступает текущему SOTA FastSolv (0,83–0,95) и заметно опережает прежний SOTA SolProp/Vermeire (1,43–2,16), причём SOTA — это *прямой чёрный ящик*, а не физика; расщепление кристалл/активность строго неидентифицируемо из растворимости и замыкается только внешними одно-компонентными данными; модель ранжирует растворители заметно лучше ($\rho_{\text{Spearman}} = 0,51$, $\text{top-1} = 0,48$), чем подсказывает её MAE, но её неопределённость сильно переуверена ($\text{PICP}_{90} = 0,13$).

Содержание

1	Введение и постановка задачи	2
2	Данные и неустранимый шумовой потолок	2
3	Термодинамическая основа	3
4	Теория: идентифицируемость и условие оптимальности	3
5	Диагностика: численная проверка теории	5
5.1	Аудит идентифицируемости/Фишера (подтверждает T1, T2, T5)	5
5.2	Робастный перезамер компенсации	5
6	Архитектура двойного заземления	6

7	Линия ThermoCurve: что сохранено, исправлено и расширено	6
8	Оценка по утилите (а не только MAE)	8
9	Сравнение с внешними моделями (FastSolv, SolProp)	8
10	Текущие результаты (сводка)	9
11	Что реализовано и проверено	10
12	Ограничения и дальнейшая работа	10
13	Заключение	10

1. Введение и постановка задачи

Цель проекта — быстрый скрининг растворимости: для строки (вещество s , растворитель v , температура T) предсказать $y = \ln x_2$ — натуральный логарифм мольной доли растворённого вещества в насыщенном растворе (типично $\ln x_2 \in [-25, 0]$). Центральный научный вопрос не “может ли нейросеть предсказывать растворимость”, а помогает ли явное термодинамическое «узкое место» по сравнению с тем же графовым энкодером, обученным напрямую на $\ln x_2$ (контроль DirectGNN).

Накопленная диагностика проекта указывает, что прямое «узкое место» не даёт выигрыша в точности (физический «налог» $\approx +0,09$ MAE на scaffold), а основное ограничение точности — *представление* (RF на дескрипторах с MAE 1,20 опережает GNN). Настоящий отчёт переформулирует задачу: мы доказываем *условие*, при котором физика оптимальна, строим архитектуру, которая это условие реализует конструктивно, и оцениваем модель метриками, отражающими реальную задачу скрининга. Эта архитектура — реализованная и исправленная форма проектной линии *ThermoCurve* (предсказание кривой, аналитика вместо численного решателя, отдельная супервизия ветвей), которую мы не отбросили, а довели до «двойного заземления» (§7).

2. Данные и неустранимый шумовой потолок

Прежде чем улучшать модель, мы оценили, есть ли вообще запас по точности. Метод. На сыром корпусе BigSolDB v2.1 (атрибуция по источнику/DOI сохранена; в обработанных сплитах она схлопнута) мы сгруппировали измерения по (вещество, растворитель, $T \pm 1$ K) и среди групп с ≥ 2 независимыми источниками измерили внутригрупповое расхождение $\ln x_2$ — нижнюю границу неустранимого шума, который не может побить никакая модель.

Таблица 1: Межисточниковое расхождение $\ln x_2$ (1687 источников, 4358 мульти-источниковых групп; лишь 97 — точные дубликаты).

Вариант	медиана	среднее	p90	CI ₉₅ (медианы)
сырой	0,031	0,161	0,450	[0,029; 0,033]
дедуп	0,033	0,165	0,461	[0,031; 0,035]

По числу источников в группе расхождение растёт ($2 \rightarrow 0,027$; $3 \rightarrow 0,091$; $4-5 \rightarrow 0,175$; $6+ \rightarrow 0,391$), но даже самые перемеренные пары держатся много ниже ошибки модели.

Две оценки пола и честная сверка. Числа выше — в нат-логе мольной доли; в $\log_{10}$ это $\approx 0,013$ (медиана) и $\approx 0,07$ (среднее). Это *оптимистичная нижняя* оценка: она измеряет согласие внутри одного корпуса по совпадающей паре/ T и занижается ре-репортами и отбором совпадающих точек. Более консервативную *межлабораторную* оценку даёт литература (FastSolv, §9): межлабораторное стандартное отклонение $0,34 \log_{10}$, типичные границы $0,5\text{--}0,7 \log_{10}$. Истинный неустрашимый пол, по-видимому, лежит между этими оценками, ближе к $0,3\text{--}0,7 \log_{10}$ ($\approx 0,7\text{--}1,6$ в нат-логе).

Вывод (исправленный). Точность *выигрываемая, но запас скромный*: наш scaffold-RMSE $\approx 1,0 \log_{10}$ выше реалистичного пола $0,3\text{--}0,7 \log_{10}$ примерно в $1,5\text{--}2$ раза, а текущий SOTA (FastSolv, $0,83\text{--}0,95 \log_{10}$ на экстраполяции) уже у *предела алеаторной неопределённости*. Значит резерв по абсолютной точности на новых каркасах — порядка фактора 2, а не порядка величины; основной выигрыш надо искать в ранжировании, температурной экстраполяции и интерпретируемости, а не в погоне за $\text{MAE} \rightarrow 0$.

3. Термодинамическая основа

Для компонента i в жидкой фазе $\mu_i^{\text{ж}} = \mu_i^0 + RT \ln(\gamma_i x_i)$. Из равенства химпотенциалов твёрдой и жидкой фаз растворённого вещества (индекс 2) следует основное уравнение равновесия твёрдое–жидкость (SLE):

$$\ln x_2 = - \underbrace{\frac{\Delta H_{\text{fus}}}{R} \left(\frac{1}{T} - \frac{1}{T_m} \right)}_{\Phi(T) \text{ (кристаллический член, зависит от } s)} - \underbrace{\ln \gamma_2(x_2, T)}_{\text{активность, зависит от } (s, v)}, \quad (1)$$

(в приближении $\Delta C_p^{\text{fus}} = 0$). Здесь $\Phi(T)$ — идеальная (кристаллическая) часть, зависящая только от свойств чистого вещества (T_m , ΔH_{fus}); $\ln \gamma_2$ — неидеальность пары.

Модели активности. Классически $\ln \gamma_2$ задаётся моделью локального состава. NRTL использует асимметричные параметры τ_{12} , τ_{21} и α ; в пределе бесконечного разбавления $\ln \gamma_2^\infty = \tau_{12} + \tau_{21} e^{-\alpha \tau_{21}}$. В упрощённом одно-параметрическом режиме $\ln \gamma_2 = \ln \gamma_2^\infty(T) (1-x_2)^2 \text{ c } \ln \gamma_2^\infty(T) = a + b (T_{\text{ref}}/T - 1)$ — аффинно по $1/T$.

COSMO-SAC (используется в нашей новой архитектуре, см. §6) выводит $\ln \gamma_2$ из σ -профилей молекул $p(\sigma)$ (гистограмма экранирующей плотности заряда) через сегментный коэффициент активности $\Gamma(\sigma)$ (неподвижная точка) и восстановительную свободную энергию — физически наиболее обоснованная инженерная модель активности.

4. Теория: идентифицируемость и условие оптимальности

Несущее ядро — результаты T1, T3, T4; расширения T2, T5 и Утв. 1 снабжены явными предположениями и численной проверкой (§5).

Предположение 1 (Активность содержит член $\propto 1/T$). Модель активности имеет свободный параметр при $1/T$ (как b выше или температурная зависимость NRTL).

Теорема 1 (Структурная неидентифицируемость). При Предположении 1 и $\Delta C_p = 0$ отображение $\theta \mapsto \{\mu(T_k; \theta)\}_k$ ранг-дефицитно в направлениях кристалл/активность при любом наборе температур: чувствительность кристаллического члена $v_k = \partial \mu(T_k) / \partial \Delta H_{\text{fus}}$ лежит в линейной оболочке столбцов активности $(1, 1/T)$. Поэтому ΔH_{fus} (и само расщепление $\Phi / \ln \gamma_2$) не идентифицируемо

из данных растворимости; информация Фишера $\mathcal{I}_{\Delta H_{\text{fus}}} = 0$. Дефицит замыкается ровно добавлением внешнего ограничения на кристаллический фактор (прямая метка ΔH_{fus} , либо фиксация наклона активности b).

Схема. $\Phi(T) = (\Delta H_{\text{fus}}/R)(1/T - 1/T_m)$ даёт лишь форму $\propto 1/T$ плюс константу; обе уже порождаются членом b/T и константой a активности. Столбец дизайна для ΔH_{fus} — линейная комбинация существующих, матрица Грама вырождена, соответствующая информация Фишера равна нулю. Добавление единичной строки по ΔH_{fus} (прямая метка) или удаление столбца b восстанавливает полный ранг. $\square$

Поправка к фольклору. Мульти-температурные данные сами по себе не идентифицируют расщепление: они лишь добавляют коллинеарные строки $\propto 1/T$. Это честная версия более ранних оценок вида $(\Delta T)^{-k}$, которые молча предполагали отсутствие свободного члена b/T .

Теорема 2 (Полупараметрическая граница, класс-зависимая). Пусть ньюисанс-активность лежит в классе $\mathcal{H}$ с проекцией на касательное пространство $\Pi_{\mathcal{H}}$. Эффективная информация о ΔH_{fus} :

$$\mathcal{I}_{\text{eff}}(\Delta H_{\text{fus}}) = \sigma^{-2} \|v - \Pi_{\mathcal{H}} v\|^2.$$

При богатом классе (свободный $1/T$) $\Pi_{\mathcal{H}} v = v$ и $\mathcal{I}_{\text{eff}} = 0$ (согласуется с T1); при ограниченном классе $\mathcal{I}_{\text{eff}} > 0$ и граница Крамера–Рао конечна.

Определение 1 (Переносимость факторов). ρ_c, ρ_a — популяционные риски лучших предсказателей кристаллического и остаточно-активного факторов при их покрытиях метками; ρ_y — риск прямого предсказателя $\ln x_2$ при покрытии только пар растворимости.

Теорема 3 (Условие оптимальности физики (главный результат)). На скаффолд-сдвинутом тесте структурированный предсказатель удовлетворяет

$$\mathcal{R}_{\text{phys}}^{\text{scaffold}} \leq \rho_c + \rho_a + \Gamma_{\text{ident}},$$

где Γ_{ident} — разрыв идентифицируемости (равен нулю при замыкании по T1). Физика строго превосходит прямой предсказатель, $\mathcal{R}_{\text{phys}}^{\text{scaffold}} < \rho_y$, тогда и только тогда, когда (i) Γ_{ident} замкнут и (ii) кристаллический фактор наследует более широкое химическое покрытие, чем пары (ρ_c мал за счёт внешнего одно-компонентного пула), а остаток активности ниже по сложности, чем совместная цель.

Схема. Разложить структурированный риск через две головы; ограничить каждую её риском переноса и липшицевостью решателя; неидентифицируемый перекрёстный член собрать в Γ_{ident} . Кристаллический фактор — одно-компонентная функция, поэтому супервизируется внешним пулом чистых компонентов много большего покрытия, чем пары; у прямого предсказателя такого доступа нет. $\square$

Следствие 1 (Механизм). Заземление Φ на внешний пул точек плавления/энтальпий (и GC-приоры) одновременно замыкает Γ_{ident} и снижает ρ_c ; симметрично, заземление активности на внешний пул σ -профилей снижает ρ_a . Оба рычага реализованы в §6.

Теорема 4 (Оптимальность температурной экстраполяции). Для экстраполяции внутри одной пары к T^* вне диапазона обучения $[T_{\min}, T_{\max}]$ структурированный (аффинный по $1/T$) класс гипотез имеет ошибку экстраполяции, ограниченную дисперсией оценки наклона, умноженной на $|1/T^* - 1/T|$, тогда как неструктурированный температурный энкодер не ограничен вне носителя обучения.

Теорема 5 (Инфо-геометрия компенсации, пояснительная). Минимальное собственное значение метрики Фишера в плоскости кристалл/активность стремится к нулю при $\Delta T \rightarrow 0$; значит компенсирующие движения по поверхности идентификации почти не стоят информации, и оптимизатор их предпочитает.

Оговорка о метрике компенсации. Поскольку $\delta\Phi + \delta \ln \gamma_2 = (\text{остаток } \ln x_2)$, корреляция $\text{corr}(\delta\Phi, \delta \ln \gamma_2) \rightarrow -1$ тривиально при улучшении подгонки $\ln x_2$, независимо от физической корректности. Поэтому робастной метрикой качества разложения мы берём систематический сдвиг $\overline{\delta\Phi}$, а не $|\text{corr}|$.

Утверждение 1 (А-оптимальная декомпозиция вспомогательных потерь). Среди неотрицательных весов вспомогательных потерь при бюджете *trace*-оптимальный выбор даёт положительный вес каждой потере, добавляющей информацию в ранг-дефицитное направление; при блочной структуре голов (обеспеченной *stop-gradient*) это выбирает ровно сигналы на кристалл, на уровень активности и на форму активности.

5. Диагностика: численная проверка теории

5.1. Аудит идентифицируемости/Фишера (подтверждает T1, T2, T5)

Мы строим матрицу чувствительности SLE-модели и информацию Фишера на безразмерных параметрах.

Таблица 2: Режимы супервизии ($\Delta T = 40$ K): обусловленность $\mathcal{I}$ и граница Крамера–Рао на ΔH_{fus} .

Режим	$\lambda_{\min}(\mathcal{I})$	$\text{cond}(\mathcal{I})$	CRLB $\text{sd}(\Delta H_{\text{fus}})$, Дж/моль
только растворимость	$5,4 \times 10^{-2}$	$2,3 \times 10^5$	19,895
+ метка T_m	2,32	$5,4 \times 10^3$	3,151
+ метки T_m и ΔH_{fus}	8,04	$1,6 \times 10^3$	1,689

Слип по ΔT (обусловленность, только растворимость): $1,7 \times 10^3$ при 120 K $\rightarrow 2,3 \times 10^5$ при 40 K $\rightarrow 1,9 \times 10^{16}$ при 10 K — узкое температурное окно делает расщепление ранг-дефицитным (T5). Класс активности (вложенное сравнение): свободный наклон $\Rightarrow \text{sd}(\Delta H_{\text{fus}}) = 19,895$, $\text{cond } 2,3 \times 10^5$; известный наклон $\Rightarrow \text{sd}(\Delta H_{\text{fus}}) = 8,251$, $\text{cond } 5,3 \times 10^2$ — идентифицируемость ΔH_{fus} зависит от класса активности (T2).

5.2. Робастный перезамер компенсации

Строгая метрика компенсации требует измеренных u T_m и ΔH_{fus} на строке, но в стандартном тест-сплите ноль строк с измеренной ΔH_{fus} ; ранее публиковавшееся $\text{corr} = -0,876$ получено на ручном наборе из 8 строк. Относительно физически обоснованного GC-эталоны (Joback) на полном тесте ($n = 5826$):

Величина	Значение
$\text{corr}(\delta\Phi, \delta \ln \gamma_2)$	-0,962
bootstrap CI ₉₅	[-0,965; -0,958]
$\overline{\delta\Phi}$ (робастная метрика)	-7,1
доля противоположных знаков	0,93

Компенсация сильная, устойчивая и отрицательная; кристаллический член систематически далёк от физического приора, а активность его почти идеально поглощает — что мотивирует заземление кристалла (и активности).

6. Архитектура двойного заземления

Логика «заземлить кристалл внешними одно-компонентными данными» симметрично переносится на активность через σ -профили. Тогда оба фактора разложения становятся одно-компонентными, внешне-супервизируемыми объектами, и условие T3 выполняется *конструктивно*.

Кристаллическая ветвь. Голова FusionHead предсказывает $(T_m, \Delta H_{\text{fus}})$ из вектора чистого вещества, заземлённая на GC-приоры (Joback, вычисляемые для любого SMILES) и на внешний пул точек плавления (open_crystal_artifact: 19,436 веществ; после честного исключения скаффолдов теста/валидации остаётся 14,792, из них 448 с ΔH_{fus}). Внешний пул подаётся отдельным вспомогательным потоком (self-solvent строки, маски только на $T_m/\Delta H_{\text{fus}}$), что $\approx 10\times$ превышает число обучающих веществ с T_m .

Активностная ветвь (новое). Сеть предсказывает σ -профиль молекулы (SigmaProfileHead: softmax по 51 бину $\times$ softplus-площадь — одно-компонентный, переносимый объект), из которого дифференцируемый слой COSMO-SAC (CosmoSacLayer) вычисляет $\ln \gamma_2$:

$$\Delta W(\sigma_m, \sigma_n) = \frac{\alpha'}{2}(\sigma_m + \sigma_n)^2 + c_{\text{hb}} \max(0, \sigma_{\text{acc}} - \sigma_{\text{hb}}) \min(0, \sigma_{\text{don}} + \sigma_{\text{hb}}), \quad (2)$$

$$\Gamma_S(\sigma_m) = \left[\sum_n p_S(\sigma_n) \Gamma_S(\sigma_n) e^{-\Delta W(\sigma_m, \sigma_n)/RT} \right]^{-1} \quad (\text{неподвижная точка}), \quad (3)$$

$$\ln \gamma_2^{\text{rest}} = \frac{A_2}{a_{\text{eff}}} \sum_m p_2^{\text{pure}}(\sigma_m) [\ln \Gamma_S(\sigma_m) - \ln \Gamma_2(\sigma_m)], \quad (4)$$

плюс опциональный комбинаторный член Ставермана–Гутгенхайма. Матрица обмена ΔW зависит только от фиксированной сетки и вычисляется один раз; сегментная неподвижная точка Γ решается ограниченной демпфированной итерацией (как SLE-решатель) и полностью дифференцируема. σ -профиль супервизируется внешней базой (VT-2005) отдельным потоком с потерей — одномерным расстоянием Вассерштейна (EMD) на форме профиля плюс MSE на площади.

Переключение. Флаг activity_model="cosmo_sac" активирует σ -ветвь вместо NRTL; путь NRTL/решателя SLE и контроль DirectGNN не затронуты. Поправочный механизм корректирует только кристаллическую сторону, активность проходит без изменений.

7. Линия ThermoCurve: что сохранено, исправлено и расширено

Архитектура двойного заземления (§6) — это реализованная и исправленная форма проектной линии *ThermoCurve*, а не отказ от неё. Здесь мы явно фиксируем происхождение идей, их математическую запись и то, что именно сохранено, исправлено и расширено.

Исходный замысел ThermoCurve. ThermoCurve — проект архитектуры второго поколения со тремя принципами: (i) предсказывать *кривую* $\widehat{C}_{s,v}: T \mapsto \widehat{\ln x_2}(T)$, а не точку; (ii) использовать *аналитическую* форму температурной зависимости активности вместо численного решателя

SLE; (iii) *декомпозировать* функцию потерь так, чтобы каждая ветвь получала независимый обучающий сигнал. Аналитическая кривая:

$$\widehat{\ln x_2}(T) = -\frac{\widehat{\Delta H_{\text{fus}}}}{R} \left(\frac{1}{T} - \frac{1}{T_m} \right) - \left[\widehat{\ln \gamma_2^\infty}(T_{\text{ref}}) + \int_{T_{\text{ref}}}^T \frac{\hat{A} + \hat{B}/T' + \hat{C} \ln T'}{R T'^2} dT' \right], \quad (5)$$

где интеграл берётся аналитически (без численного ОДУ-решателя). Декомпозиция потерь:

$$\mathcal{L} = \mathcal{L}_{\text{SLE}} + \lambda_c \mathcal{L}_{\text{crystal}} + \lambda_{\text{IDAC}} \mathcal{L}_{\text{IDAC}} + \lambda_{\text{CF}} \mathcal{L}_{\text{CF}} + \lambda_{\text{int}} \mathcal{L}_{\text{integral}} + \lambda_{\text{mono}} \mathcal{L}_{\text{mono}}, \quad (6)$$

где $\mathcal{L}_{\text{crystal}}$ — прямые метки $T_m, \Delta H_{\text{fus}}$; $\mathcal{L}_{\text{IDAC}}$ — $\ln \gamma_2^\infty$; $\mathcal{L}_{\text{CF}}$ — контрфактический сигнал уровня (для одного вещества в двух растворителях разность $\ln x_2$ при T_{ref} ограничивает разность $\ln \gamma_2^\infty$); $\mathcal{L}_{\text{integral}}$ — чистый сигнал на форму кривой через температурные разности $\ln x_2(T_k) - \ln x_2(T_j)$ одной пары; $\mathcal{L}_{\text{mono}}$ — мягкая монотонность $\partial \ln x_2 / \partial T \geq 0$.

Что сохранено и реализовано. Все три принципа ThermoCurve — костяк нашей архитектуры. Соответствие компонентов:

Компонент ThermoCurve	Наша реализация	Статус
Кривая $T \mapsto \ln x_2$ (не точка)	аналитический активностный путь + SLE-баланс по (1)	сохранено
Аналитика вместо численного решателя	дифф. активностный слой (замкнутый γ_∞ / COSMO-SAC с ограниченной итерацией) + неявное дифференцирование	сохранено
$\mathcal{L}_{\text{crystal}}(T_m, \Delta H_{\text{fus}})$	FusionHead + GC-приоры + внешний кристалл-пул (aux-поток)	сохранено и расширено
$\mathcal{L}_{\text{IDAC}}$	супервизия $\ln \gamma_2^\infty$ + IDAC aux-поток	сохранено
$\mathcal{L}_{\text{integral}}$ (форма)	pair-temperature van't Hoff / $\Delta \ln x_2$ + exact-joint supervision	сохранено (частично)
$\mathcal{L}_{\text{CF}}$ (уровень)	ранжирование по T внутри пары + декорр-диагностика	частично
$\mathcal{L}_{\text{mono}}$	монотонность по T (фаза 3)	сохранено
Форма активности (A, B, C) /Лежандр	заменена на σ -профиль → COSMO-SAC	расширено
Башня CRLB-теорем	ранговая T1 + полупараметрика T2 + условие T3	исправлено
corr = -0,876 на 8 строках	робастный полнотестовый GC-замер (-0,962, с оговоркой)	исправлено

Что исправлено. В исходном предложении ThermoCurve теоретическая часть была внутренне противоречива: конечная граница Крамера–Рао (его Теорема 1.1) противоречила собственному следствию о нулевой эффективной информации; содержала ошибку в линейной оболочке ($v = u - 1/T_m \in \text{span}(1, u)$); а оценка $(\Delta T)^{-4}$ молча отбрасывала свободный член B/T активности. Мы заменили эту башню корректным ранговым результатом T1, класс-зависимой полупараметрической

границей T2 и условием оптимальности T3 (§4). Эмпирику компенсации на 8 строках ($\text{corr} = -0,876$) мы заменили устойчивым полнотестовым замером относительно GC-эталоны ($-0,962$, $n = 5826$), с честной оговоркой о тривиальности самой корреляции (§5).

Что расширено (двойное заземление). ThermoCurve заземлял только кристаллическую ветвь; его форма активности (A, B, C) не имела прямых меток и обучалась лишь косвенно через интегральный/разностный сигнал. Мы сделали активностную ветвь *тоже* внешне-заземлённой: сеть предсказывает σ -профиль (одно-компонентный, переносимый объект), супервизируемый внешней базой, который подаётся в дифференцируемый COSMO-SAC. В результате оба фактора разложения становятся одно-компонентными внешне-супервизируемыми объектами — это строго сильнее одиночного (кристаллического) заземления ThermoCurve и есть конструктивная реализация условия T3: COSMO-SAC физичнее трёх-параметрической формы и сам несёт правильную температурную зависимость через $\Delta W/RT$.

Вывод по линии ThermoCurve. Мы её не отбросили: её ядро (кривая, аналитика, отдельная супервизия) сохранено и составляет костяк архитектуры; слабые места (противоречивая CRLB-теория, 8-строчная эмпирика, бедная параметризация активности) исправлены; а само заземление расширено с одного фактора до двух.

8. Оценка по утилите (а не только MAE)

Абсолютный MAE по $\ln x_2$ — неверная метрика для выбора растворителя и чувствителен к шуму и систематическим сдвигам. Мы добавили оценку, отражающую реальную задачу.

Ранжирование растворителей. Для каждой группы (вещество, T) с ≥ 3 растворителями ранжируем растворители по предсказанной и измеренной $\ln x_2$ (инвариантно к сдвигам и шуму меток). Прокси-TGNN на scaffold-тесте (826 групп, в среднем 6,3 растворителя):

ρ_{Spearman}	Kendall τ	top-1 (лучший растворитель)	NDCG@3
0,51	0,44	0,48	0,73

То есть при «плохом» MAE 1,74 модель выбирает лучший растворитель в 48% случаев (против $\approx 16\%$ случайно) — практическая полезность много выше, чем подсказывает MAE.

Калибровка неопределённости. Многоуровневый PICP + регрессионная ECE + «резкость» с учётом шумового потолка (MC-dropout). Прокси-TGNN сильно переуверен: при номинальном покрытии 90% реальное — лишь 0,13 (ECE = 0,69; средний std 0,28, что $1,7\times$ шумового потолка). Штатная проверка только на 90% недооценила бы это. Решение реализовано: split-конформное предсказание даёт *гарантированное* маргинальное покрытие независимо от того, насколько неверна собственная σ модели — на том же прокси-TGNN номинал 90% даёт эмпирические 0,918 (ширина $\pm 1,5 \log_{10}$, что честно отражает трудную scaffold-неопределённость; адаптивный нормированный вариант сужает интервалы там, где модель уверена). Вывод: исходная неопределённость переуверена, но конформ делает её *валидной для применения*.

9. Сравнение с внешними моделями (FastSolv, SolProp)

Прямое сравнение требует осторожности: внешние модели предсказывают $\log_{10} S$ в *молярности* (моль/л), а мы — $\ln x_2$ в *мольной доле*. Пересчёт: $\ln \rightarrow \log_{10}$ делением на $\ln 10 = 2,303$; переход

молярная доля $\rightarrow$ молярность — аддитивный сдвиг $\approx +1$ на растворитель (влияет на уровень, почти не на разброс). Поэтому RMSE сопоставимы с точностью $\pm 0,1-0,2 \log_{10}$. Наш TGNN: RMSE 2,34 нат-лог $\rightarrow 1,02 \log_{10}$; MAE 1,74 $\rightarrow 0,76 \log_{10}$.

Таблица 4: Строгая экстраполяция на *новые вещества*, RMSE в $\log_{10}$ (органика, Т-зависимость). Внешние числа — из FastSolv (Nature Comm. 2025) и SolProp/Vermeire (JACS 2022).

Модель	Тип	Тест	RMSE $\log_{10}$
FastSolv (SOTA, 2025)	прямой/чёрный ящик	SolProp (var- T)	0,83
FastSolv	прямой/чёрный ящик	Leeds (room- T)	0,95
Наша (TGNN/DirectGNN)	физ-информ.	BigSolDB scaffold	$\approx 1,0$
SolProp/Vermeire (2022)	физ-информ. (термо-цикл)	SolProp	1,43
SolProp/Vermeire	физ-информ.	Leeds	2,16
(справка) FastSolv	интерполяция	BigSolDB train/val	0,22

Вердикт. На сопоставимом режиме (новые вещества, органика, Т-зависимость) наш $\approx 1,0 \log_{10}$: *немного хуже* текущего SOTA FastSolv (0,83–0,95) и *заметно лучше* прежнего SOTA SolProp/Vermeire (1,43–2,16). Мы в той же лиге, что современные модели, чуть позади лидера. (Оговорка: тест-сеты не совпадают — наш scaffold-сплит BigSolDB против их внешних Leeds/SolProp; пересчёт единиц приблизителен.)

Ключевое наблюдение. SOTA-модель FastSolv — это *прямой чёрный ящик* (дескрипторы fastprop + ансамбли + очищенный BigSolDB 2.0), *без* термодинамического узкого места; а физ-информированный SolProp — *позади* неё. Это внешне подтверждает наш внутренний вывод: физический bottleneck не выигрывает в сырой точности, а рычаг — представление, данные и ансамбли, а не топология энкодера. Отсюда честная ниша нашей работы — не «побить MAE», а *конкурентная с SOTA, но интерпретируемая и заземлённая на оба фактора* модель, с акцентом на температурную экстраполяцию (FastSolv платбит у ~ 350 К, где принципиальная физика Т-зависимости — наше преимущество).

10. Текущие результаты (сводка)

Таблица 5: Опорные числа (scaffold-сплит, если не указано иное).

Модель / метрика	MAE	R^2	Примечание
DirectGNN	1,652	0,478	лучший по MAE
RF (гибрид)	1,722	0,449	сильный дескрипторный бейзлайн
TGNN (MPNN)	1,741	0,438	физика, текущий «налог» +0,09
RF (дескрипторы)	1,20	—	узкое место = представление
pair van't Hoff (Т-экстрап.)	0,368	0,887	оракул структуры по $1/T$
Шумовой потолок $\ln x_2$	медиана 0,031 / среднее 0,161 (§2)		
Ранжирование (TGNN)	Spearman 0,51, top-1 0,48 (§8)		
Калибровка (TGNN)	PICP ₉₀ = 0,13, ECE 0,69 (§8)		

11. Что реализовано и проверено

Все локально-выполнимые компоненты реализованы и покрыты тестами (полный набор: 284 теста зелёные):

- Phase A: скрипт оценки шумового потолка (сырой BigSolDB).
- Phase B1: дифференцируемый CosmoSacLayer (сегментная неподвижная точка, предвычисленная ΔW , restoring + комбинаторный член), подключён через `activity_model="cosmo_sac"` к решателю SLE.
- Phase B2: SigmaProfileHead и переключение голов в модели.
- Phase B3: внешняя σ -супервизия — builder потока, ingestion VT-2005, потеря EMD, хук в тренере, CLI; полный прогон `cosmo_sac+ $\sigma$` работает end-to-end.
- Phase C: ранжирование (Spearman/Kendall/top-1/NDCG) и калибровка неопределённости (PICP/ECE, noise-floor-aware).

12. Ограничения и дальнейшая работа

- Сырой scaffold-MAE ограничен энкодером ($\sim 93\%$ разрыва до RF — представление, не физический слой); мы *не* заявляем SOTA по MAE.
- Per-molecule ΔH_{fus} слабо покрыт метками ($\sim 2\%$); опора на GC-приоры и энтропийное (Walden) ограничение.
- GC-эталон в диагностике компенсации — прокси, не истина; робастен знак и относительный $\overline{\delta\Phi}$, не абсолют.
- $\text{corr}(\delta\Phi, \delta \ln \gamma_2) \rightarrow -1$ тривиально улучшается с подгонкой $\ln x_2$; отчётная метрика — $\overline{\delta\Phi}$.
- Нужны данные/вычисления: реальная база σ -профилей (VT-2005; opencosmorspy её не предоставляет) для настоящего покрытия супервизии; GPU для полноценного прогона `cosmo_sac vs gamma_inf` и скаффолд/температурных протоколов.
- Неопределённость требует рекалибровки (temperature scaling / ансамбли).

13. Заключение

Физика помогает обобщению ровно тогда, когда её факторизация идентифицируема, а факторы переносимее совместной цели. Практическое следствие — заземлять оба фактора на внешние одно-компонентные данные (точки плавления для кристалла, σ -профили для активности). Шумовой потолок показывает, что точность выигрываемая; диагностика подтверждает неидентифицируемость и её замыкание внешними метками; оценка по утилите показывает, что модель уже полезна для ранжирования, хотя её неопределённость требует калибровки. Архитектура двойного заземления построена и протестирована; остаются данные (σ -база) и вычисления (GPU).