

Краткий отчёт о проделанной работе по проекту TGNN-Solv

Физически информированная графовая модель для предсказания растворимости

Поломошнов Никита Львович

18 апреля 2026 г.

Краткое содержание

В проекте построена и проверена физически информированная графовая модель для предсказания растворимости твёрдых органических соединений в жидких растворителях [14, 15, 16]. Этот текст является кратким отчётом о текущем этапе, а не заявлением о завершённом превосходстве физического пути. Целевая величина — натуральный логарифм мольной доли растворённого вещества в насыщенном растворе,

$$y = \ln x_2.$$

Главная идея модели TGNN-Solv состоит в том, чтобы не предсказывать растворимость напрямую, а провести вычисление через термодинамическое уравнение твёрдо-жидкого равновесия [3, 4]:

$$\ln x_2 = -\Phi(T) - \ln \gamma_2, \quad \Phi(T) = \frac{\Delta G_{\text{fus}}(T)}{RT}. \quad (1)$$

Здесь $\Phi(T)$ описывает вклад плавления чистого твёрдого вещества, а γ_2 — коэффициент активности растворённого вещества в растворе. Для честного контроля реализована модель DirectGNN: она использует тот же графовый блок обработки молекул, но предсказывает $\ln x_2$ напрямую, без физического слоя.




Рис. 1: Сравнимые вычислительные пути. TGNN-Solv проводит предсказание через физические параметры и решатель равновесия; DirectGNN использует тот же молекулярный блок, но предсказывает $\ln x_2$ напрямую.

На основном разбиении по новым молекулярным каркасам получено:

Модель	MAE по $\ln x_2$	R^2	Комментарий
DirectGNN	1.652	0.478	лучшая средняя ошибка в одном запуске
Случайный лес, гибридные признаки	1.722	0.449	сильная не нейросетевая проверка
TGNN-Solv	1.741	0.438	физический путь уступает на 0.089




Рис. 2: Текущее сравнение основных моделей на тестовых срезах. График подчёркивает, что DirectGNN имеет лучшую среднюю ошибку, а TGNN-Solv остаётся близкой, но уступает в этом запуске.

Текущий результат требует аккуратной интерпретации. Физическая модель реализована, устойчиво обучается и выигрывает у DirectGNN примерно на 46% тестовых строк. Однако по средней ошибке на новых каркасах она уступает прямой модели. Это означает, что в текущей версии физическое ограничение не даёт выигрыша на основном структурном разбиении. Доверительный интервал для разрыва 0.089 ещё не оценён, поэтому статистический вывод требует нескольких инициализаций.

Отдельный аудит трудных систем показывает, что часть тяжёлых ошибок связана не только с архитектурой. В каркасном тесте 6.6% строк имеют формальный заряд, 3.6% являются явными солями, 3.5% — цвиттер-ионами. На нейтральных строках DirectGNN даёт $MAE = 1.604$, а TGNN-Solv — 1.701; на всех зарядовых строках ошибки возрастают до 2.337 и 2.309. На 26 экстремально плохо растворимых заряженных или антоцианидин-подобных строках ошибка превышает 11 по $\ln x_2$; 20 из этих строк приходятся на дельфинидин-хлорид в ацетоне и этаноле. Исходная статья по дельфинидину описывает чистые растворители, но в обработанных строках нет T_m и ΔH_{fus} , поэтому требуемую активность через кристаллический вклад посчитать нельзя. Поэтому следующий шаг для таких случаев — аудит кристаллических данных и условий эксперимента, а не немедленное добавление электролитного NRTL.

При этом отдельная температурная проверка показывает, что физический сигнал в данных очень силён. Это именно режим известной пары: аудит подтвердил, что все 1751 пар из высокотемпературного теста присутствуют в низкотемпературной обучающей части. Если для такой пары построить зависимость Вант-Гоффа по низкотемпературным точкам, то высокотемпературные точки предсказываются с ошибкой $MAE = 0.368$. Это парно-подогнанный ориентир, а не конкурент для новых химических систем. Краткие локальные запуски нейросетевых моделей существенно хуже: DirectGNN даёт $MAE = 1.619$, TGNN-Solv — $MAE = 1.945$. Следовательно, проблема не в отсутствии термодинамического сигнала, а в том, что текущая обучаемая модель не извлекает его из данных достаточно хорошо.

Утверждение	Основание	Статус
DirectGNN является сильной контрольной моделью	scaffold split и внешние ориентиры	подтверждено
TGNN-Solv платит небольшую цену за физический слой	разница +0.089 MAE в одном запуске	диагностировано
Температурная физика в данных выражена сильно	Вант-Гофф даёт MAE = 0.368	подтверждено
Краткий TGNN-запуск не восстанавливает парную активность	почти постоянные NRTL-параметры	диагностировано
Полезность новых стабилизирующих компонентов	IDAC, UNIFAC, явные H, T _{IMP} , парные потери	требует планового бюджета

1. Ключевые термины

Термин	Краткое пояснение
$\ln x_2$	Логарифм мольной доли растворяемого вещества; основная целевая величина.
Твёрдо-жидкое равновесие	Равенство химических потенциалов вещества в кристалле и насыщенном растворе; физическая основа TGNN-Solv.
Графовая модель	Модель, которая читает молекулу как граф атомов и химических связей.
Молекулярный каркас	Остов молекулы по Мёрко; разбиение по каркасам проверяет перенос на новые структурные классы.
NRTL	Модель коэффициентов активности в неидеальном растворе.
IDAC	Коэффициент активности при бесконечном разбавлении; дополнительный прямой сигнал для NRTL-параметров.

2. Задача

Для заданных структуры растворяемого вещества, структуры растворителя и температуры требуется предсказать равновесную растворимость в форме $\ln x_2$. Такая величина нужна при выборе растворителя, разработке кристаллизации, очистке вещества и ранней оценке пригодности лекарственных молекул. Экспериментально измерять каждую новую пару вещество–растворитель при нескольких температурах дорого, поэтому расчётная модель полезна только тогда, когда она переносится на новые молекулы и новые температурные области.

Сложность задачи в том, что растворимость зависит и от чистого кристалла, и от жидкой смеси. На кристаллическую часть влияют температура плавления, энтальпия плавления, жёсткость и упаковка молекулы. На часть раствора влияют полярность, водородные связи, донорно-акцепторные свойства, размер молекул и совместимость функциональных групп.

Проект сравнивает два подхода:

1. **TGNN-Solv**: графовая модель предсказывает физические параметры, после чего решается уравнение твёрдо-жидкого равновесия;

2. **DirectGNN**: та же графовая обработка молекул, но прямой выход на $\ln x_2$.

Такой контроль нужен, чтобы отделить вклад графового представления от вклада физического ограничения.

3. Данные

Основной корпус построен на базе BigSolDB v2.1 и текущих обработанных таблиц проекта [1, 2]. Полные обработанные таблицы содержат 127 088 строк; из них 108 287 строк имеют целевую растворимость. В подмножестве с метками растворимости есть 1 525 уникальных растворяемых веществ, 212 растворителей и 12 129 уникальных пар. Температуры лежат в диапазоне 243.15–425.77 K, медианная температура равна 303.15 K.

Подготовка данных была самостоятельной частью работы. Все записи приводятся к единому контракту: канонические SMILES, температура в Кельвинах, целевая величина $\ln x_2$, явные маски для отсутствующих физических меток и сохранение происхождения строк. Это позволяет обучать модель на разреженной физической разметке без подстановки нулей вместо отсутствующих значений.

Показатель	Значение
Все строки в обработанных таблицах	127 088
Строки с целевой растворимостью	108 287
Уникальные растворяемые вещества с метками растворимости	1 525
Уникальные растворители с метками растворимости	212
Уникальные пары с метками растворимости	12 129
Диапазон температур	243.15–425.77 K
Среднее число строк на пару	8.93
Медианное число температурных строк на пару	9
Дубликаты троек вещество–растворитель–температура	0

Основной режим оценки — разбиение по молекулярным каркасам растворяемого вещества. Это строгий режим: модель должна работать на новых структурных классах, а не просто интерполировать между уже виденными строками.

Отдельно собран корпус IDAC — коэффициентов активности при бесконечном разбавлении. Стартовый набор был не частью BigSolDB, а отдельным ThermoML-корпусом: 9 вручную выбранных DOI из `idac_seed_dois.txt`, официальные NIST ThermoML JSON-записи, фильтрация бинарных жидкофазных IDAC-измерений, перевод InChI в SMILES через RDKit и сохранение γ^∞ , $\ln \gamma^\infty$, метода, фазы, стандартного состояния и DOI-источника [8, 9, 10]. Он содержал 404 экспериментальные строки и 138 пар. Для расширения был реализован извлекатель из NIST ThermoML: он находит DOI в архиве, загружает ThermoML JSON, выбирает бинарные измерения γ^∞ , переводит структуры в SMILES через RDKit, считает $\ln \gamma^\infty$ и агрегирует дубликаты по паре и температуре. Итоговый расширенный корпус содержит 14 900 строк, 3 145 пар, 136 растворяемых веществ, 112 растворителей и 63 DOI; конфликтующих агрегированных групп не найдено. Точное пересечение с SLE-парами и SLE-тройками равно 0%, поэтому эти данные не являются утечкой растворимости.

IDAC подключается не как строки растворимости, а отдельным обучающим потоком с маской активности. Это принципиально: IDAC измеряет предел активности, а не насыщенную растворимость. Его роль — ограничить NRTL-ветвь и уменьшить компенсаторную неоднозначность между кристаллическим вкладом и активностью раствора.

Вода сохранена в корпусе как растворитель. Для неё реализован отдельный режим графового представления с явными водородами: вместо одноузлового графа O используется граф H—O—H. Это устраняет вырожденный случай, в котором передача сообщений по химическим связям почти не работает [12, 11].




Рис. 3: Исправление графа воды и малых молекул: явные водороды возвращают O—H связи в граф и дают модели доступ к полярной структуре молекулы.

4. Контекст сравнения

TGNN-Solv сопоставляется не только с собственной прямой моделью DirectGNN. В проекте поддерживаются также случайный лес на молекулярных признаках и внешние ориентиры SolProp и FastSolv [15, 16]. Это важно методически: если DirectGNN находится на уровне внешних моделей, то качество данных и графового представления в целом достаточно сильное; тогда отставание TGNN-Solv следует искать в физическом пути, а не в общей инфраструктуре.

Классы методов различаются по смыслу. Дескрипторные модели и прямые графовые модели обычно дают один численный ответ [12, 13]. Термодинамические модели вроде NRTL и UNIFAC описывают коэффициенты активности, но требуют параметров или покрытия функциональных групп [5, 6, 7]. TGNN-Solv пытается объединить эти подходы: графовая часть предсказывает параметры, а физическое уравнение задаёт форму итогового расчёта.

5. Термодинамическая постановка

В равновесии химический потенциал растворяемого вещества в твёрдой фазе равен химическому потенциалу в жидком растворе [3, 4]. Для раствора:

$$\mu_2^{\text{liq}}(T, P, x) = \mu_2^{\text{liq},0}(T, P) + RT \ln(\gamma_2 x_2).$$

После введения свободной энергии плавления

$$\Delta G_{\text{fus}}(T) = \mu_2^{\text{liq},0}(T) - \mu_2^{\text{sol},0}(T)$$

получается уравнение (1). В приближении $\Delta C_p^{\text{fus}} = 0$ кристаллический вклад равен

$$\Phi(T) = \frac{\Delta H_{\text{fus}}}{R} \left(\frac{1}{T} - \frac{1}{T_m} \right).$$

Для активности используется модель NRTL с параметрами τ_{12} , τ_{21} и α [5]. При бесконечном разбавлении:

$$\ln \gamma_2^\infty = \tau_{12} + \tau_{21} \exp(-\alpha \tau_{21}).$$

Эта формула используется для подключения IDAC-данных.




Рис. 4: Разложение предсказания растворимости на кристаллический вклад $\Phi(T)$ и вклад активности $-\ln \gamma_2$. Именно это разложение делает промежуточные параметры физически проверяемыми.

6. Что реализовано

Реализованы полный путь TGNN-Solv, контрольная DirectGNN, решатель равновесия, несколько режимов графового кодирования молекул, обработка воды с явными водородами, расширенный

обучающий сигнал по коэффициентам активности при бесконечном разбавлении, UNIFAC-псевдометки, температурные разбиения, внешние сравнения с SolProp и FastSolv, а также диагностические программы для анализа ошибок.

Архитектура включает больше, чем один стандартный графовый блок. Базовый MPNN дополняется опциональными вариантами GPS/GraphGPS и TIMP: первый добавляет глобальное внимание, второй разделяет сообщения на дисперсионный и полярно-ассоциативный каналы. Для построения пары используется перекрёстное внимание, после которого возможна остаточная смесь экспертов по типу растворителя. Итоговая коррекция в TGNN-Solv тоже остаётся физической: модель предлагает ограниченные поправки к параметрам и повторно решает SLE, а не добавляет свободный сдвиг к $\ln x_2$.

В части данных реализованы не только финальные таблицы, но и воспроизводимые программы: подготовка основных разбиений, извлечение IDAC из ThermoML, построение отдельного IDAC-потока, UNIFAC-псевдометки, температурные разбиения и диагностические аудиты.

7. Как обучается модель

TGNN-Solv обучается не одним шагом, а поэтапно. Сначала возможен этап предобучения графового блока: восстановление маскированных атомов и связей, предсказание RDKit-дескрипторов и контрастная задача на разных представлениях одной молекулы. Этот этап нужен для химически осмысленной инициализации, но сам по себе не решает задачу совместимости вещества и растворителя; поэтому отдельно подготовлены парные задачи, контрастное выравнивание по параметрам Хансена и диагностика каналов TIMP.

Основное обучение состоит из трёх фаз. В первой фазе сильнее используются вспомогательные физические свойства: T_m , ΔH_{fus} , параметры Хансена и IDAC. Во второй фазе включается полный SLE-путь и доминирует ошибка по растворимости. Третья фаза выполняет тонкую настройку с меньшим шагом. Такой порядок нужен, чтобы случайные начальные NRTL-параметры не ломали решатель и не давали бессмысленные градиенты.

Функция ошибки складывается из основной ошибки Хьюбера по $\ln x_2$ и вспомогательных физических членов:

$$\mathcal{L} = \lambda_{\text{sol}}\mathcal{L}_{\text{sol}} + \lambda_{\text{cryst}}\mathcal{L}_{\text{cryst}} + \lambda_{\text{IDAC}}\mathcal{L}_{\text{IDAC}} + \lambda_{\text{temp}}\mathcal{L}_{\text{temp}} + \lambda_{\text{reg}}\mathcal{L}_{\text{reg}}.$$

Здесь отсутствующие метки маскируются, а IDAC используется только как отдельный сигнал для коэффициентов активности. Это принципиально: IDAC не является строкой растворимости и не должен искусственно добавляться в SLE-таблицу. В ранних версиях также были проверены более агрессивные физические штрафы: мостовой компонент оказался потенциально опасным для систем с водородными связями, а локальный штраф Вант-Гоффа требовал стабилизации масштаба, чтобы не подавлять основную ошибку по растворимости.

8. Основные результаты

Разные разбиения показывают, что главная трудность — перенос на новые растворимые вещества и новые каркасы:

Разбиение	MAE	R^2	Вывод
Случайные строки	0.166	0.987	слишком лёгкий режим
Случайные пары	0.783	0.806	компоненты обычно уже видны
Новый растворитель	0.732	0.735	относительно легче
Новое вещество	1.642	0.420	основная сложность
Новый каркас	1.703	0.462	новая структура и смещение распределения

Внешние сравнения подтверждают уровень прямой графовой модели. SolProp при переобучении на тех же целевых величинах на разбиении по новым веществам даёт $MAE = 1.624$ и $R^2 = 0.388$; DirectGNN имеет близкую $MAE = 1.652$, но более высокий $R^2 = 0.478$. FastSolv после исправления проблем с преобразованием единиц запускается корректно, но остаётся слабее: $MAE = 1.941$, $R^2 = 0.226$.

Температурная экстраполяция даёт наиболее важный физический результат. Протокол был дополнительно проверен: низкотемпературная обучающая и высокотемпературная тестовая части имеют 100% пересечение пар; вода составляет 12.2% тестовых строк; положительный сдвиг растворимости при переходе к высоким температурам наблюдается у 99.6% пар. Поэтому слабость нейросетевых кратких запусков нельзя объяснить тем, что тест состоит в основном из воды или систем с обратным температурным трендом.

Метод	MAE	R^2	Правильное направление
Вант-Гофф для каждой пары	0.368	0.887	99.0%
Линейная зависимость от T	0.414	0.850	99.0%
Случайный лес с температурой	1.290	0.658	40.4%
DirectGNN, краткий запуск	1.619	0.283	—
TGNN-Solv, краткий запуск	1.945	0.060	—




Рис. 5: Температурная экстраполяция внутри известной пары. Аналитическая форма Вант-Гоффа резко превосходит нейросетевые краткие запуски, что является главным аргументом в пользу полноценной проверки физического пути.

Этот результат показывает, что термодинамическая форма зависимости от температуры действительно содержится в данных. При этом Вант-Гофф в этой таблице является парно-подогнанным ориентиром, а не честным конкурентом для прогноза новых пар: он явно использует низкотемпературные точки той же пары. Следующий научный вопрос — может ли TGNN-Solv при плановом обучении приблизиться к этому физическому пределу и использовать температурную форму лучше прямой модели.

Дополнительная диагностика показала, где именно ломается краткий запуск TGNN-Solv. На парах с как минимум тремя высокотемпературными точками медианная ошибка наклона $\ln x_2$ от $1/T$ равна 763 K для парной аппроксимации Вант-Гоффа, 1158 K для TGNN-Solv и 1630 K для DirectGNN. При этом общая ошибка TGNN-Solv всё равно хуже: $MAE = 1.945$. Причина видна во внутренних величинах: стандартное отклонение предсказаний TGNN-Solv составляет только 0.582 при истинном 2.560, τ_{12} почти не меняется от пары к паре ($\sigma \approx 4.8 \cdot 10^{-5}$), а средняя финальная поправка к физическому выходу равна всего $1.1 \cdot 10^{-5}$. То есть в этом коротком запуске NRTL-ветвь фактически не выучила парную активность, а модель даёт слишком сжатый набор температурных кривых.




Рис. 6: Диагностика значения и наклона на температурной экстраполяции. Краткий запуск TGNN-Solv частично восстанавливает знак и масштаб наклона, но проигрывает по уровню $\ln x_2$ и даёт слишком сжатые предсказания.

Дополнительно реализованы прикладные и диагностические слои: быстрое применение модели, температурное сканирование, ранжирование растворителей и оценка технологического окна. Отдельно поддерживаются оценка неопределённости через случайное выключение нейронов или ансамбли и проверка области применимости по расстоянию в пространстве скрытых представлений и сходству отпечатков Моргана по Танимото. Эти блоки не подменяют научное сравнение моделей, но показывают, что проект доведён до воспроизводимого исследовательского контура.

Итог

К настоящему моменту выполнена основная методическая и программная часть проекта: подготовлены данные, реализованы две сопоставимые модели, проведены внешние сравнения, проверены температурные режимы и разобраны основные источники ошибки. DirectGNN лучше TGNN-Solv по средней ошибке на новых каркасах в одном поддерживаемом запуске, но температурные эксперименты показывают сильный физический сигнал, который текущая обучаемая TGNN-Solv не использует полностью. Последняя диагностика делает это утверждение конкретным: в кратком запуске TGNN-Solv почти не варьирует NRTL-параметры по парам, поэтому физическая часть раствора не несёт достаточной химической информации.

Главный результат этого этапа состоит в уточнении научного вопроса. Теперь нужно проверить не абстрактную идею «добавить физику», а конкретную гипотезу: сможет ли физический путь при плановом обучении восстановить температурную структуру данных лучше прямой модели, не теряя при этом качества на новых молекулярных каркасах.

Список литературы

- [1] Krasnov, L., Malikov, D., Kiseleva, M., Tatarin, S., Sosnin, S., Bezzubov, S. BigSolDB 2.0, dataset of solubility values for organic compounds in different solvents at various temperatures. *Scientific Data*, 2025. <https://doi.org/10.1038/s41597-025-05559-8>
- [2] BigSolDB 2.1: A Comprehensive Dataset of Solubility Values for Organic Compounds in Organic Solvents and Water at Various Temperatures. Zenodo, 2026. <https://zenodo.org/records/15094979>
- [3] Prausnitz, J. M., Lichtenthaler, R. N., de Azevedo, E. G. *Molecular Thermodynamics of Fluid-Phase Equilibria*. 3rd ed. Prentice Hall, 1998.
- [4] Hildebrand, J. H., Prausnitz, J. M., Scott, R. L. *Regular and Related Solutions*. Van Nostrand Reinhold, 1970.
- [5] Renon, H., Prausnitz, J. M. Local compositions in thermodynamic excess functions for liquid mixtures. *AIChE Journal*, 14(1), 135–144, 1968. <https://doi.org/10.1002/aic.690140124>
- [6] Fredenslund, A., Jones, R. L., Prausnitz, J. M. Group-contribution estimation of activity coefficients in nonideal liquid mixtures. *AIChE Journal*, 21(6), 1086–1099, 1975. <https://doi.org/10.1002/aic.690210607>
- [7] Weidlich, U., Gmehling, J. A modified UNIFAC model. 1. Prediction of VLE, hE, and gamma-infinity. *Industrial & Engineering Chemistry Research*, 26(7), 1372–1381, 1987. <https://doi.org/10.1021/ie00067a018>
- [8] TGNN-Solv External IDAC Starter Corpus. Zenodo, 2026. Files: idac.csv, idac_seed_dois.txt. <https://zenodo.org/records/19484205>
- [9] Frenkel, M., Chirico, R. D., Diky, V., et al. XML-Based IUPAC Standard for Experimental, Predicted, and Critically Evaluated Thermodynamic Property Data Storage and Capture (ThermoML). *Pure and Applied Chemistry*, 78(3), 541–612, 2006. <https://doi.org/10.1351/pac200678030541>
- [10] National Institute of Standards and Technology. ThermoML Archive. <https://www.nist.gov/mml/acmd/trc/thermoml/thermoml-archive>
- [11] Landrum, G. RDKit: Open-source cheminformatics software, 2024. <https://www.rdkit.org>
- [12] Gilmer, J., Schoenholz, S. S., Riley, P. F., Vinyals, O., Dahl, G. E. Neural message passing for quantum chemistry. *Proceedings of ICML*, 2017. <https://proceedings.mlr.press/v70/gilmer17a.html>
- [13] Yang, K., Swanson, K., Jin, W., et al. Analyzing learned molecular representations for property prediction. *Journal of Chemical Information and Modeling*, 59(8), 3370–3388, 2019. <https://doi.org/10.1021/acs.jcim.9b00237>
- [14] Boobier, S., Hose, D. R. J., Blacker, A. J., Nguyen, B. N. Machine learning with physicochemical relationships: solubility prediction in organic solvents and water. *Nature Communications*, 8, 1600, 2017. <https://doi.org/10.1038/s41467-017-01920-0>

- [15] Vermeire, F. H., Chung, Y., Green, W. H. Predicting solubility limits of organic solutes for a wide range of solvents and temperatures. *Journal of the American Chemical Society*, 144(24), 10785–10797, 2022. <https://doi.org/10.1021/jacs.2c01768>
- [16] Attia, L., Burns, J. W., Doyle, P. S., et al. Data-driven organic solubility prediction at the limit of aleatoric uncertainty. *Nature Communications*, 16, 7497, 2025. <https://doi.org/10.1038/s41467-025-62717-7>